



**Amirkabir University of Technology**  
**(Tehran Polytechnic)**



**Department of**  
**Computer Engineering**

# Course : Machine Learning

## Homework 4

Najmeh Mohammadbagheri

99131009

## بخش تشریحی

### سوال اول

الف) بله. چون در این الگوریتم سعی می‌شود مقادیر متناظر با خط جداکننده پیدا شود. این خط نیز به توزیع داده‌ها بستگی دارد. بنابراین در الگوریتم SVM یادگیری بر توزیع داده‌هاست و پارامترهای خط به توزیع داده‌ها بستگی دارد. این توضیحات مربوط به SVM پایه است. در مورد SVMهای غیرخطی این مطلب صحیح نیست و غیرپارامتری هستند.

ب) بله. حاشیه‌ی هر مدل میزان عملکرد آن مدل در مقابل داده‌های تست را نشان می‌دهد. هرچه این حاشیه بیشتر باشد مدل بهتر است و کمتر دچار اشتباه در تصمیم‌گیری می‌شود.

ج) خیر. در SVM پایه که hard است بردارهای پشتیبان شدیداً به داده‌ها حساس است و دچار بیش‌برازش می‌شود ولی در نسخه‌ی soft آن میتوان با ضریب بتا این میزان بیش‌برازش شدن را کاهش داد.

د) خیر. داده‌های نویزی و پرت در تعیین حاشیه در حالت سخت (hard SVM) تاثیر دارد. ولی در حالت نرم (soft SVM) میتوان تاثیر این داده‌ها را با کم در نظر گرفتن میزان جریمه، کاهش داد.

ه) خیر. اگر این دسته‌بند ضعیف یک دسته‌بند تصادفی باشد در هر اجرا از داده‌های آموزش برچسب مختلف به داده‌ها می‌زند و اصلاً رفتار قابل پیش‌بینی‌ای ندارد. ولی اگر یک دسته‌بند معقول و غیرتصادفی باشد این گزاره صحیح است.

و) خیر. اگر خطای یک دسته‌بند بیشتر از ۵۰ درصد باشد باید ضریب منفی به آن بدهیم که که نتیجه را معکوس کند تا عملکرد همچنان خوب باشد. اگر هم دسته‌بند تصادفی بود ضریب صفر به آن می‌دهیم که نتیجه اش اصلاً در نظر گرفته نشود.

### سوال دوم

هرچه سیگما کوچکتر باشد، گاما بزرگتر است و میدانیم که هر چه گاما بزرگتر باشد درجه غیرخطی بودن مرز تصمیم بیشتر میشود بنابراین سیگما در تصویر اول از سمت راست ۰.۲ و در تصویر وسط ۱۰ و در تصویر سمت چپ ۱ است.

### سوال سوم

در روش hard تنها تعداد هر کلاس رای‌گیری میشود. یعنی اگر ۵ مورد کلاس A داشته باشیم و ۴ مورد کلاس B خروجی کلاس A است. اما در روش soft احتمال هر کلاس را داریم و از این احتمال‌ها میانگین گرفته میشود و در آخر کلاس با بیشترین احتمال به عنوان جواب اعلام میشود. توضیح با مثال:

Classifier 1 predicts class A with probability 99%

Classifier 2 predicts class A with probability 49%

Classifier 3 predicts class A with probability 49%

The average probability of belonging to class A across the classifiers is  
 $(99 + 49 + 49) / 3 = 65.67\%$ . Therefore, class A is the ensemble decision

سوال چهارم  
روش hard :

Classifier 1 predicts class 2

Classifier 2 predicts class 1

Classifier 3 predicts class 1

➔ data belongs to class 1

روش Soft:

The average probability of belonging to class 1 across the classifiers is

$$(0.2 + 0.6 + 0.8) / 5 = 0.32$$

The average probability of belonging to class 2 across the classifiers is

$$(1 + 0.3 + 0.6) / 5 = 0.38$$

The average probability of belonging to class 3 across the classifiers is

$$(0.8 + 0.1 + 0.6) / 5 = 0.3$$

➔ data belongs to class 2

بخش پیاده‌سازی

سوال اول

قسمت اول :

بهترین پارامترها با رنگ سبز مشخص شده اند.

کرل خطی :

C = 0	C = 3	C=10	C = 60
: Accuracy ۰.۸۷۷۵۵۱۰۲۰۴۰۸۱۶۳۲	: Accuracy ۰.۸۵۷۱۴۲۸۵۷۱۴۲۸۵۷۱	: Accuracy ۰.۸۷۷۵۵۱۰۲۰۴۰۸۱۶۳۲	: Accuracy ۰.۸۳۶۷۳۴۶۹۳۸۷۷۵۵۱۱
: Fscore ۰.۹۲۸۵۷۱۴۲۸۵۷۱۴۲۸۶	: Fscore ۰.۹۱۷۶۴۷۰۵۸۸۲۳۵۲۹۴	: Fscore ۰.۹۱۸۹۱۸۹۱۸۹۱۸۹۱۹	: Fscore ۰.۸۹۴۷۳۶۸۴۲۱۰۵۲۶۳۲

کرل چند جمله‌ای:

Degree = 3 , c =1	Degree = 5 , c =5	Degree = 10 , c = 1	Degree = 50, c = 1
Accuracy : ۰.۸۹۷۹۵۹۱۸۳۶۷۳۴۶۹۴	Accuracy : ۰.۸۳۶۷۳۴۶۹۳۸۷۷۵۵۱۱	Accuracy : ۰.۸۱۶۳۲۶۵۳۰۶۱۲۲۴۴۹	Accuracy : ۰.۷۷۵۵۱۰۲۰۴۰۸۱۶۳۲۶
Fscore: ۰.۹۴۲۵۲۸۷۳۵۶۳۲۱۸۳۹	Fscore: ۰.۹	Fscore: ۰.۸۸۶۰۷۵۹۴۹۳۶۷۰۸۸۶	Fscore: ۰.۸۷۳۵۶۳۲۱۸۳۹۰۸۰۴۶

کرل RBF:

Gamma = 1	Gamma =10	Gamma = 0.1	Gamma = 0.001
: Accuracy ۰.۶۹۳۸۷۷۵۵۱۰۲۰۴۰۸۲	: Accuracy ۰.۷۵۵۱۰۲۰۴۰۸۱۶۳۲۶۵	: Accuracy ۰.۸۵۷۱۴۲۸۵۷۱۴۲۸۵۷۱	: Accuracy ۰.۸۹۷۹۵۹۱۸۳۶۷۳۴۶۹۴
: Fscore ۰.۸۱۹۲۷۷۱۰۸۴۳۳۷۳۴۹	: Fscore ۰.۸۶۰۴۶۵۱۱۶۲۷۹۰۶۹۷	: Fscore ۰.۹۲۱۳۴۸۳۱۴۶۰۶۷۴۱۶	: Fscore ۰.۹۳۵۰۶۴۹۳۵۰۶۴۹۳۵

کرل سیگموئید:

C = 1	C = 10	C = 50	C = 0.1
: Accuracy ۰.۷۳۴۶۹۳۸۷۷۵۵۱۰۲۰۴	: Accuracy ۰.۷۷۵۵۱۰۲۰۴۰۸۱۶۳۲۶	: Accuracy ۰.۷۹۵۹۱۸۳۶۷۳۴۶۹۳۸۸	: Accuracy ۰.۷۷۵۵۱۰۲۰۴۰۸۱۶۳۲۶
: Fscore ۰.۸۴۷۰۵۸۸۲۳۵۲۹۴۱۱۸	: Fscore ۰.۸۷۳۵۶۳۲۱۸۳۹۰۸۰۴۶	: Fscore ۰.۸۸۶۳۶۳۶۳۶۳۶۳۶۴	: Fscore ۰.۸۷۳۵۶۳۲۱۸۳۹۰۸۰۴۶

قسمت دوم:

کرل خطی تنها یک پارامتر  $C$  دارد که با تغییر دادن آن تنها بایاس مدل بالا پایین میشود و تاثیری در شکل مدل ندارد.

کرل چندجمله‌ای دو پارامتر درجه و  $C$  دارد که با افزایش پارامتر  $d$ ؛ یعنی درجه، میزان پیچیدگی مدل افزایش میابد و با زیاد شدن هرچه بیشتر آن بیش برازش بیشتری صورت می‌گیرد. تاثیر  $C$  نیز مانند حالت قبل است.

کرل RBF یک پارامتر گاما دارد که هرچه گاما بیشتر باشد پیچیدگی مدل بیشتر است و در نتیجه مدل بر داده‌ها منطبق میشود و بیش برازش رخ میدهد.

کرل سیگنویید یک پارامتر  $C$  دارد که این پارامتر نیز با توجه به آزمایشها بیشتر بودنش بهتر است. ولی از حدی نباید بیشتر شود. چون عملکرد کاهش می‌یابد.

قسمت سوم :

یک روش ساده که به ذهنم میرسد، این است که در یک بازه‌ی معقول تعداد زیادی مقدار تولید کنیم و به ازای تمام این مقادیر مدل را بسازیم. سپس به ازای هر مدل مساحت زیر نمودار ROC را برای محاسبه کنیم و این مقادیر را نگه داریم. در نهایت پارامتر متناظر با مدلی که بیشترین مساحت زیر سطح نمودار را داشت، به عنوان بهترین پارامتر انتخاب کنیم. (اگر داده‌ها توازن نداشتند میتوانیم به جای استفاده از نمودار ROC از نمودار  $\text{precision\_recall}$  استفاده کنیم).

همچنین میتوانیم برای دقت بالاتر، این محاسبات را بر روی داده‌های ارزیابی انجام دهیم. (استفاده از روش‌های cross-validation و k-fold)

## سوال دوم

قسمت الف:

N_features = 3 N_estimators = 20 Max_depth = 3	N_features = 5 N_estimators = 40 Max_depth = 2	N_features = 8 N_estimators = 100 Max_depth = 4
Accuracy 0.7662337662337663	accuracy 0.7727272727272727	accuracy 0.7987012987012987

(من با مقادیر مختلف زیادی امتحان کردم، به ازای مقادیر مختلف بازه‌ی تغییرات بسیار کم بود.)

قسمت ب:

`N_estimators` تعداد مدل‌هایی که یادگیری میشوند را بیان میکند. در نهایت نیز برای پیش‌بینی داده‌های تست از خروجی تمام این مدل‌ها میانگین گرفته میشود. در روش جنگل تصادفی باید میزان این پارامتر بالا تنظیم شود تا عملکرد نهایی این روش قابل قبول باشد.

`N_features` بیانگر تعداد ویژگی‌هایی است که برای هر مدل داده میشود. ایده‌ی جنگل تصادفی این است که علاوه بر اینکه هر مدل بر روی داده‌های مجزایی کار میکند، ویژگی‌های مختلفی نیز به هر مدل داده شود. با مشخص کردن این پارامتر در واقع میگوییم به هر مدل به صورت تصادفی چندتا از ویژگی‌ها داده شود. این کار باعث میشود که میزان تصادفی بودن مدل‌ها افزایش یافته و نتیجه‌ی نهایی بایاس نشده باشد.

`Max_depth` نیز بیانگر عمق درخت در هر مدل است. هدف از این روش جنگل تصادفی این بود که مدل‌ها همگی عمق خیلی کمی داشته باشند و سعی شود که از بیش‌برازش شدن جلوگیری شود. پس باید دقت کنیم که عمق درخت خیلی کم در نظر گرفته شود. در کل ترکیبی از این سه پارامتر باید منطقی باشد که دقت بالا بدست آوریم. مثلاً تعداد ویژگی ۳ و عمق درخت ۸ اصلاً انتخابی منطقی نیست. چون با ۳ ویژگی نمیتوانیم که به عمق ۸ برسیم!

قسمت سوم:

1. Adaboost with `n_estimators = 200`

accuracy Adaboost : 0.8311688311688312

2. SVM with RBF kernel , `gamma=0.01`

accuracy SVM RBF : 0.8246753246753247

3. Bagging with `base_estimator = LogisticRegression()`

accuracy Bagging : 0.8181818181818182